

Layman to Layman

Basics of NLP/LLM

VarCamp 2025

Sept. 7, 2025



Thura Aung

thuraaung.ai.mdy@gmail.com

Software Engineering (International Program)

King Mongkut's Institute of Technology Ladkrabang

- Lab. Member, Language Understanding Lab, Myanmar.
- AI Engineer Intern (Part-time), AI Singapore/ NUS, Singapore.
- Machine Learning Research (Part-time), Looloo Tech, Thailand.

Intelligence

- Intelligence is a continuum not a dichotomy.
- ဉာဏ်ရည် အဆင့်အတန်း ဟူသည် ပျံ့နှံ့သည့်သဘော၊ ပကတိ အစွန်းရောက် မဟုတ်
- လူသား သည် ဘာသာစကားကြောင့် တိုးတက်
- လူ့ဘာသာစကားဟာ လူမဟုတ်တဲ့ တခြားတိရစ္ဆာန်တွေရဲ့ ဘာသာစကားနဲ့ မတူပါ
- compositional/productive (“အဓိပ္ပာယ်ရှိတဲ့ အသုံးအနှုန်းတွေက တခြားအဓိပ္ပာယ်ရှိတဲ့ အသုံးအနှုန်းတွေကနေ တည်ဆောက်ထားတာ”) ဖြစ်ပါတယ်
- open-ended → အချိန်ကြာလာတာနဲ့အမျှ စကားလုံးအသစ်တွေနဲ့ စာကြောင်းအသစ်တွေ ထပ်မံဖန်တီးလာနိုင်ပါတယ်
- abstract → စိတ္တဇ (ဒြပ်ကင်းသဘော) နာမ်တွေကို ဖော်ပြနိုင်

<https://cims.nyu.edu/ai/educational-programs/broad-interest-courses/big-ideas-artificial-intelligence/>

Learning

- အတွေ့အကြုံများမှ ဉာဏ်ရည်ပေါ်ထွက်လာသည်

ကျွန်တော်တို့ ဘယ်လို "သိ"ကြတာလဲ

- အရာဝတ္ထုတွေနဲ့ အပြန်အလှန်ဆက်ဆံခြင်းအားဖြင့်: မြင်ခြင်း၊ ကြားခြင်း၊ ထိတွေ့ခြင်း၊ အရသာခံခြင်း စသည်ဖြင့်



ကျွန်တော်တို့ဟာ ကျွမ်းကျင်မှုတွေကို ဘယ်လို "သင်ယူ"ကြတာလဲ။

- လက်တွေ့လုပ်ဆောင်ကြည့်ခြင်းအားဖြင့်: လမ်းလျှောက်ခြင်း၊ ပြေးခြင်း၊ နောက်ပြန်ပစ်ခြင်း (back-flip)၊ ချက်ပြုတ်ခြင်း စသည်ဖြင့်

ဒဏ္ဍာရီထဲက ပျူစောထီးကို မြင်ဖူးလား?

- အရေးအသား၊ အပြောအဆိုက တဆင့် သိရတာ (အမှန် အမှား အကုန်ပါ)

ဘာသာစကားတွေလည်း မတူ






Data as Vector


$$\begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & -1 \end{bmatrix}$$

Row-Vector Space

Dimension = 2




$$\text{sim}(A, B) = \cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$



Cosine Similarity

Bag of Word

- ဝါကျရဲ့အဓိပ္ပာယ်ကို စကားလုံးတွေ တစ်လုံးချင်းစီ ဘယ်နှစ်ခါပါလဲဆိုတာကို ကြည့်ပြီး ဆုံးဖြတ်ခြင်း
- စကားလုံးများကို discrete symbols များအဖြစ်ဖော်ပြခြင်း
- ဆန့်ကျင်ဘက် စကားလုံးတွေ စကားလုံး စီစဉ်ပုံတွေ ဆင်တူတဲ့စကားလုံးတွေကို ထည့်သွင်းစဉ်းစားမထားပါ



- စကားလုံးများကို one-hot vectors များဖြင့် ဖော်ပြနိုင်ပါတယ်။
- Vector dimension = ဝေါဟာရစကားလုံးအရေအတွက်

Distributional hypothesis

- စကားလုံးတွေဟာ ဆင်တူတဲ့ context တွေမှာ တွေ့ရတတ်ပြီး
- အဲဒါတွေဟာ ဆင်တူတဲ့ အဓိပ္ပာယ်တွေ ရှိတတ်ကြပါတယ်
- *You shall know a word by the company it keeps*
- အဓိပ္ပာယ်ဟာ စကားလုံးကိုယ်တိုင်မှာ မရှိဘဲ၊ စကားလုံးပေါ်လာတဲ့ context မှာပဲ ရှိပါတယ်။
- context ကို ကျယ်ကျယ်ပြန့်ပြန့် အနက်ဖွင့်သင့်တယ်။
- Textual context
- Multimodal context




မြေစိမ်း



တောဝက်




J.R.Firth, 1957



Hamilton WL, Leskovec J, Jurafsky D. 2016. Diachronic word embeddings reveal statistical laws of semantic change, In Proc. of ACL

Word Vectors

- Word vector ဆိုတာ word co-occurrence matrix ထဲက row တစ်ခုဖြစ်ပါတယ်
- ဆင်တူတဲ့ word vectors တွေရှိတဲ့ စကားလုံးတွေဟာ အဓိပ္ပာယ်ဆင်တူကြပါတယ်
- Word vectors တွေဟာ sparse နဲ့ high-dimensional ဖြစ်ကြပါတယ်
- စကားလုံးအများစုနဲ့ စကားစုတွေဟာ အတူတူမရှိကြတဲ့အတွက် zeros တွေ အများကြီးပါဝင်လို့ပါ
- Solution: **Word Vector Compression** → ဆင်တူတဲ့ စကားလုံးတွေကို တစ်ခုနဲ့တစ်ခု နီးကပ်စေ
- **Co-occurrence count** ကို word နဲ့ phrase vectors က ခန့်မှန်းမယ် [Mikolov et al., 2013]



Word Vectors (Cont'd)

- Word vectors တွေဟာ compositional ဖြစ်ပါတယ်
- Compositionality ကို vector arithmetics အဖြစ် သတ်မှတ်နိုင်ပါတယ်
- Word vector arithmetics (e.g. Russia - Beijing + China = Moscow)

Querying analogy for: လက်ရှည် - လက်တို + ဘောင်းဘီရှည်
 Analogies result:
 Word: ဝတ်, Score: 0.5567076206207275
 Word: ဖိုသီဖတ်သီ, Score: 0.5551380515098572
 Word: အင်္ကျီ, Score: 0.5383158326148987
 Word: ထိုင်မသိမ်း, Score: 0.5366981625556946
 Word: ထဘီ, Score: 0.5333731174468994
 Word: အဝါနု, Score: 0.5322700142860413
 Word: ညအိပ်ဝတ်ရုံ, Score: 0.5307892560958862
 Word: ဝတ်ဆင်, Score: 0.5197224020957947
 Word: အင်္ကျီ, Score: 0.519253671169281
 Word: ရေညှော်, Score: 0.5191075205802917

Vector for 'အမေ':
 [0.03071883 -0.25971985 0.40830743 0.11242703 -0.12839618 -0.00550127
 0.05469747 -0.10745972 -0.15699431 0.3023142 -0.29259813 0.16690251
 0.07785437 -0.58479047 -0.7412099 -0.04547881 -0.03287222 -0.11044414
 -0.08638554 -0.02459145 -0.08973993 -0.02339625 -0.28159484 0.24005242
 0.0358529 -0.6657557 0.27617294 -0.59123087 0.1455806 0.18249877
 0.12091456 -0.4804478 -0.00294562 -0.56233424 0.278252 0.11192498
 0.14295132 0.05967402 -0.12034112 0.05577437 -0.293318 -0.31646758
 0.21822222 -0.40633217 0.17665516 0.2565288 -0.14461318 -0.08262646
 0.4971917 0.3262872 0.09940107 0.18980542 -0.04641127 0.9501322
 0.08271138 0.02752739 -0.17911749 -0.22868471 0.34966385 0.13285655
 -0.06082508 -0.1977889 0.9427577 0.50436085 0.2823574 -0.19498166
 0.1311327 -0.09055237 0.31270525 0.13989182 -0.84258276 0.30009115
 -0.3908675 0.14674334 -0.4403673 -0.3262866 -0.26670656 0.24394107
 0.18048933 -0.23953764 0.02176909 -0.29563728 0.10838298 0.12806904
 0.09947888 0.0433741 -0.11379734 0.20521459 0.01840506 0.24994595
 0.24415538 -0.19377986 -0.1143683 -0.30197594 0.12075205 -0.24896991
 -0.11793793 0.49135238 0.0792672 0.16126719]


Nearest neighbors for 'အင်တာနက်':
 Score: 0.697070837020874, Word: မြန်မာနက်
 Score: 0.6930655837059021, Word: တာနကာ
 Score: 0.6491116881370544, Word: ဘောနက်
 Score: 0.6279654502868652, Word: အင်တာနာ
 Score: 0.6255528926849365, Word: တာဝါတိုင်
 Score: 0.609035849571228, Word: ကွန်ရက်လှိုင်း
 Score: 0.598670482635498, Word: ဖေ့ဘွတ်
 Score: 0.5967662334442139, Word: မိုဘိုင်းဖုန်း
 Score: 0.5892794132232666, Word: ဒေတာ
 Score: 0.5861119627952576, Word: လူမှုကွန်ရက်

$$v_{\text{cat}} = \begin{pmatrix} -0.224 \\ 0.130 \\ -0.290 \\ 0.276 \end{pmatrix} \quad v_{\text{dog}} = \begin{pmatrix} -0.124 \\ 0.430 \\ -0.200 \\ 0.329 \end{pmatrix}$$

$$v_{\text{the}} = \begin{pmatrix} 0.234 \\ 0.266 \\ 0.239 \\ -0.199 \end{pmatrix} \quad v_{\text{language}} = \begin{pmatrix} 0.290 \\ -0.441 \\ 0.762 \\ 0.982 \end{pmatrix}$$




Hinton



Neural Network တွေ သုံးပြီး semantic net က တဆင့် distributed representation တွေ လေ့လာခဲ့

Hinton, Geoffrey E., "Learning Distributed Representations of Concepts." Proceedings of the Eighth Annual Conference of the Cognitive Science Society, Erlbaum, 1986, pp. 1-12.




Mikolov

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. In 1st International Conference on Learning Representations, ICLR 2013, Scottsdale, Arizona, USA, May 2-4, 2013, Workshop Track Proceedings.


Word Vectors (Cont'd)

- Unsupervised learning ကို နှစ်ခုစလုံးက အသုံးပြုထားတဲ့အတွက် human label တွေ မလိုအပ်ပါဘူး။
- CBOW: context စကားလုံးများပေါ်မူတည်ပြီး target စကားလုံးကို ခန့်မှန်းပါတယ်။
- CBOW က embeddings တွေကို သင်ယူပြီး ဆင်တူတဲ့ context တွေကနေ စကားလုံးတစ်ခုတည်းကို ခန့်မှန်းနိုင်ပါတယ်။
- Skipgram- target စကားလုံးတစ်ခုပေးထားရင် context စကားလုံးတွေကို ခန့်မှန်းပါတယ်။ (CBOW ရဲ့ ပြောင်းပြန်)
- Skip-gram က target စကားလုံးတစ်ခုစီအပေါ် အာရုံစိုက်တဲ့အတွက် ရှားပါးတဲ့စကားလုံးတွေအတွက် ပိုကောင်းပါတယ်။
- Word2Vec, GloVe, fastText



context ဟာ စကားလုံး တစ်ခုချင်းစီရဲ့ အဓိပ္ပာယ်ကို

ဖြစ်ပေါ်စေပါတယ်






စကားလုံး တစ်ခုချင်းစီနဲ့ ၎င်းတို့ရဲ့ အထားအသို က

စာသားရဲ့ အဓိပ္ပာယ် (context) ကို ဖြစ်ပေါ်စေပါတယ်


စကားလုံးတစ်ခုဟာ သူ့ရဲ့ဘေးပတ်ဝန်းကျင်က စကားလုံးတွေပေါ်မှာ အဓိပ္ပာယ်သက်ရောက်ပါတယ်

Neural Networks

- လူ့ဦးနှောက်ကို အခြေခံပြီး၊ အချင်းချင်းချိတ်ဆက်ထားတဲ့ nodes (neurons) တွေရဲ့ layer တွေနဲ့ ဖွဲ့စည်းထားပါတယ်
- Input Layer – Train data တွေကို လက်ခံရယူပါတယ် (ဥပမာ- စာသား၊ ပုံရဲ့ pixels တွေ)
- Hidden Layers – data ကို weights နဲ့ activation functions တွေအသုံးပြုပြီး လုပ်ဆောင်ပါတယ်
- Output Layer – ခန့်မှန်းချက်တွေကို ထုတ်လုပ်ပေးပါတယ် (ဥပမာ- class labels, ကိန်းဂဏန်းတွေ)



Warren McCulloch



Walter Pitts

Language Models

$$P(S) = \prod_{i=1}^n P(w_i | w_{i-1})$$

- ဘာသာစကား မော်ဒယ် language model (LM) ဟာ အရင်စကားလုံးတွေကို အခြေခံပြီး နောက်ထပ်စကားလုံးကို ခန့်မှန်းပါတယ်
- RNNs (Recurrent Neural Networks) တွေက အရှေ့က အချက်အလက်တွေကို hidden state ကို အသုံးပြုပြီး မှတ်သားထားနိုင်တယ်
- ရိုးရှင်းတဲ့ feed-forward network နဲ့မတူဘဲ၊ RNN က အချက်အလက်တွေကို စကားလုံးတစ်လုံးချင်းစီက ယူပါတယ်။
- သူ့ရဲ့ မှတ်ဉာဏ် (hidden state) ကို update လုပ်ပါတယ်။
- အဲဒီမှတ်ဉာဏ်ကို အသုံးပြုပြီး နောက်ထပ်စကားလုံးကို ခန့်မှန်းပါတယ်။
- အားနည်းချက် - Context ရှည်ရင် မမှတ်နိုင်



Bengio








Figure: Sebastian Raschka, Mehdi Mirjalili, Python Machine Learning, 3rd Edition, Birmingham, UK: Packt Publishing, 2019

A Neural Probabilistic Language Model" is cited as: Bengio, Y., Ducharme, R., Vincent, P., & Jauvin, C. (2003

Polysemy

စကားလုံး/token တစ်ခုမှာ အဓိပ္ပာယ်တစ်ခုထက်ပိုရှိနေခြင်း

Homonymy သံတူကြောင်းကွဲမဟုတ်

ဥပမာ

မင်း

- ကြံယာထောက်ပစ္စည်း၊ လွန်ကဲခြင်းအနက်ဖြင့်ကြံယာကိုထောက်ပံ့သောစကားလုံး → အိုမင်း၊ လွန်မင်း၊ ကြောက်မင်း။
- နာမ်စား၊ ရာထူးကြီးမြင့်သူကမိမိအောက်မှငယ်သားတို့အားရည်ညွှန်းသောစကားလုံး → မင်းသိသမျှ ငါ့ကို ပြော။
- နာမ်စား၊ မိမိကဦးတည်ပြောဆိုသူကိုရည်ညွှန်းသောစကားလုံး → သူငယ်ချင်း၊ မင်းနဲ့ ငါ အတူသွားမယ်နော်။
- နာမဝိသေသန၊ ဂုဏ်ပြု ချီးမြှင့်ခေါ်သော စကားလုံး → လူကြီးမင်း၊ ဦးမင်း။
- နာမ်၊ အစိုးရအမှုထမ်းအကြီးအကဲ → တပ်မင်း၊ ဗိုလ်မင်း အပေါင်းတို့ သည်လည်း။
- နာမ်၊ ဘုရင့်ဆွေတော်မျိုးတော် → သားတော်အိမ်ရှေ့မင်း။
- နာမ်၊ ဘုရင် → မင်းတို့စကား၊ မိုးကြိုးသွား။



Transformer Embeddings



$$\text{softmax}\left(\frac{Q \times K^T}{\sqrt{d_k}}\right) V$$



Noam Shazeer



Ashish Vaswani



- Self-attention - တစ်ခုနဲ့တစ်ခု ပုံပြီး ဆင်တူတဲ့ tokens တွေကို အဓိပ္ပာယ်တစ်ခုတည်းဆီကို ရောက်အောင်ကြိုးစားခြင်း
- အစောပိုင်း context tokens တွေက နောက်ပိုင်း tokens တွေရဲ့ embedding representations ကို သက်ရောက်မှုရှိပါတယ်
- သိအိုရီအရ context token တစ်ခုစီဟာ စာကြောင်းတစ်ခုလုံးရဲ့ အဓိပ္ပာယ်ကို ထည့်သွင်းနိုင်ပါတယ်
- Transformers တွေက tokens တွေကို တပြိုင်နက်တည်း လုပ်ဆောင်ပါတယ် (တစ်လုံးပြီးမှတစ်လုံးဖတ်တဲ့ RNNs တွေနဲ့မတူပါဘူး)
- Problem → Transformers တွေက စကားလုံးအစီအစဉ်ကို မူလကတည်းက မသိပါ
- Solution → Positional Encoding: မော်ဒယ်က tokens တွေရဲ့ အစီအစဉ်ကို သိအောင်လို့ input embeddings တွေထဲကို positional signal တစ်ခု ထည့်ပေးရပါမယ်

<https://jalammar.github.io/illustrated-transformer/>


<https://web.stanford.edu/~jurafsky/slp3/slides/transformer24aug.pdf>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017).

Attention is all you need. In *Advances in Neural Information Processing Systems* (pp. 5998–6008).

Subword tokenization

- အသုံးများတဲ့ algorithm သုံးမျိုးရှိပါတယ်
 - Byte-Pair Encoding (BPE) (Sennrich et al., 2016)
 - Unigram language modeling tokenization (Kudo, 2018)
 - WordPiece (Schuster and Nakajima, 2012)
- Tokenization Algorithm သုံးမျိုးစလုံးမှာ ပါဝင်တဲ့ အစိတ်အပိုင်းနှစ်ခု ရှိပါတယ်
 - A token learner: Raw training corpus တစ်ခုကိုယူပြီး ဝေါဟာရ (tokens အစုအဝေး) ကို ထုတ်လုပ်ပေးပါတယ်
 - A token segmenter: Raw test sentence တစ်ခုကိုယူပြီး အဲဒီဝေါဟာရအရ tokenization လုပ်ပေးပါတယ်
- များသောအားဖြင့် အသုံးများတဲ့ စကားလုံးတွေ ပါဝင်ပါတယ်
- အသုံးများတဲ့ subwords တွေလည်း ပါဝင်ပါတယ်
- ၎င်းတို့ဟာ မကြာခဏဆိုသလို -est သို့မဟုတ် -er လိုမျိုး morpheme တွေဖြစ်တတ်ပါတယ်
- Morpheme ဆိုတာ ဘာသာစကားတစ်ခုရဲ့ အသေးငယ်ဆုံး အဓိပ္ပာယ်ရှိတဲ့ အစိတ်အပိုင်းတစ်ခုပါ
- ဥပမာ- "unlikeliest" မှာ "un-", "likely" နဲ့ "-est" ဆိုပြီး morpheme သုံးခုရှိပါတယ်



Subword tokenization (Cont'd)


Byte Pair Encoding (BPE) token learner

- ဝေါဟာရကို တစ်ဦးချင်းစီ အက္ခရာအားလုံးရဲ့ အစုအဝေးအဖြစ် သတ်မှတ်လိုက်ပါ။ ဥပမာ- {က, ခ, ဂ, ဃ...}
- အောက်ပါအဆင့်တွေကို ထပ်ခါတလဲလဲ လုပ်ဆောင်ပါ။
 - training corpus ထဲမှာ အများဆုံး တွဲဖက်တွေ့ရတဲ့ သင်္ကေတနှစ်ခု (ဥပမာ- 'က'၊ 'ခ') ကို ရွေးချယ်ပါ။
 - ပေါင်းစည်းထားတဲ့ သင်္ကေတအသစ် 'ကခ' ကို ဝေါဟာရထဲကို ထည့်သွင်းပါ။
 - corpus ထဲမှာ တွဲနေတဲ့ 'ကခ' တွေကို 'ကခ' နဲ့ အစားထိုးပါ။
- သတ်မှတ်ထားတဲ့ ပေါင်းစည်းမှု (k merges) ပြည့်တဲ့အထိ လုပ်ဆောင်ပါ။

Byte Pair Encoding (BPE) token segmenter

- Test data ပေါ်မှာ training data ကနေ သင်ယူခဲ့တဲ့ ပေါင်းစည်းမှုတွေကို အောက်ပါအတိုင်း run ပါ
 - Greedily
 - သင်ယူခဲ့တဲ့ အစဉ်လိုက်အတိုင်း
 - (test frequencies တွေက အခန်းကဏ္ဍကနေ မပါဝင်ပါ)
- ဒါကြောင့်၊ ပထမဆုံး 'ေရ' ကို 'ရေ' အဖြစ် ပေါင်းစည်းပါ။ ပြီးတော့ 'ရွက်ပြာ' ကို 'ရွက်ပြော' အဖြစ် ပေါင်းစည်းပါ။ ရလဒ်-
- Test set က "က နီ" ကို tokenized လုပ်ရင် တစ်လုံးတည်းဖြစ်တဲ့ "ကနီ" ဖြစ်ပါမယ်။
- Test set က "က ယ် ဆယ် ရေး" ကို tokenized လုပ်ရင် "ကယ်" နဲ့ "ဆယ်ရေး" ဆိုပြီး tokens နှစ်ခုဖြစ်လာနိုင်ပါတယ်။

Masked Language Modeling



- ဘာသာစကား နားလည်မှုအတွက် Transformer-based မော်ဒယ်တစ်ခုဖြစ်ပါတယ်
- စာသားကို နှစ်လမ်းသွား လုပ်ဆောင်ပါတယ် (ဘယ်ဘက်နဲ့ ညာဘက် context ကို ထည့်သွင်းစဉ်းစားပါတယ်)
- contextual word embeddings တွေကို ထုတ်လုပ်ပေးပါတယ်
- အသုံးများတဲ့ subwords တွေ သုံးမယ်

ကွက်လပ်ဖြည့်ပါ

1. မနက်ခင်းမှာ ကျွန်တော် _____ သောက်တယ်။
2. ကျောင်းမှာ ကျွန်တော်တို့ _____ လေ့လာတယ်။
3. ကျွန်မ မိခင်ကို _____ လို့ ခေါ်တယ်။ (အမေ၊ မေမေ...)



Devlin et al., 2019 – BERT: Pre-training of Deep Bidirectional Transformers. arXiv:1810.04805
<https://jalamar.github.io/illustrated-bert/>

Masked Language Modeling (Cont'd)

Pretraining


- ဘာသာစကား representations တွေကို သင်ယူဖို့
- corpus ကြီး တွေပေါ်မှာ တစ်ကြိမ်ပဲ လုပ်ဆောင်ပါတယ် (unsupervised)
- Masked Language Modeling (MLM)- စာကြောင်းထဲက ဖုံးကွယ်ထားတဲ့ စကားလုံးတွေကို ခန့်မှန်းခြင်း
- Next Sentence Prediction (NSP)- စာကြောင်း B က စာကြောင်း A ရဲ့ နောက်မှာ ပါမပါ ခန့်မှန်းခြင်း

Finetuning


- သီးခြား downstream task တစ်ခုချင်းစီအတွက် လုပ်ဆောင်ပါတယ် (supervised)
- သီးခြား downstream task အတွက် သီးခြား layer တစ်ခုကို ထပ်ထည့်ရပါတယ် (ဥပမာ- classification, QA)
- သီးခြား downstream task ရဲ့ data နဲ့ train ပြီး BERT ရဲ့ weights အားလုံး ဒါမှမဟုတ် အချို့ကို update လုပ်ပါတယ်
- Text Classification, POS Tagging, NER Tagging, Question Answering.

Sentence Embeddings

- Vector Space မှာ ဘေးချင်းကပ်နေတဲ့ စာကြောင်းတွေဟာ ဆင်တူကြပါတယ်
- Vector Space မှာ ဘေးချင်းမကပ်တဲ့ စာကြောင်းတွေကတော့ မဆင်တူကြပါဘူး
- Transformer ရဲ့ pre-trained embeddings တွေနဲ့ initialize ပြီး contrastive learning ကို အသုံးပြုပြီး စာကြောင်းတွေကြားက embeddings တွေကို သင်ယူပါတယ်




RAG



အမေးအဖြေတွေ ဖြေတဲ့အခါ (သို့) စာသားတွေကို ထုတ်ပေးတဲ့အခါမှာ၊

- RAG က ပထမဆုံးအနေနဲ့ သက်ဆိုင်ရာ အချက်အလက်တွေကို Database/Documents တွေထဲကနေ ရှာဖွေယူပါတယ်
- ပြီးမှ အဲဒီအချက်အလက်တွေပေါ် အခြေခံပြီး LLM တွေက အဖြေတွေကို ထုတ်ပေးပါတယ်။
- RAG ဟာ LLM တွေနဲ့ အပြင်ဘက်က ဗဟုသုတ ရင်းမြစ် (ဥပမာ- စာအုပ်တွေ၊ ဆောင်းပါးတွေ) ကို ပေါင်းစပ်လိုက်တာဖြစ်ပါတယ်။
 - Retrieval (ရှာဖွေခြင်း) - ပထမအဆင့်မှာ မေးခွန်းနဲ့ သက်ဆိုင်တဲ့ အချက်အလက်တွေကို သီးခြားဒေတာဘေ့စ် (knowledge base) ထဲကနေ ရှာဖွေစုဆောင်းပါတယ်။
 - Generation (ထုတ်ပေးခြင်း) - ဒုတိယအဆင့်မှာတော့ ရှာတွေ့ထားတဲ့ အချက်အလက်တွေကို LLM ကို ထည့်သွင်းပေးပြီး စနစ်တကျနဲ့ ယုတ္တိရှိတဲ့ အဖြေတစ်ခုကို ထုတ်ပေးဖို့ ညွှန်ကြားပါတယ်။



LIMIT




Figure 4 | Scores on the LIMIT small task (N=46) over embedding dimensions. Despite having just 46 documents, model struggle even with recall@10 and cannot solve the task even with recall@20.

- Single-vector: Document တစ်ခုစီက vector တစ်ခုစီ ဖြစ်ပါတယ်
 - Retrieval က vector space မှာ အနီးဆုံး vector ကို ရှာဖွေတာ ဖြစ်ပါတယ်
 - အဓိပ္ပါယ်မျိုးစုံ ဒါမှမဟုတ် ရှုပ်ထွေးတဲ့ ဆက်ဆံရေးတွေကို မဖော်ပြနိုင်ပါ
- Multi-vector: Document တစ်ခုစီက set of vectors (tokens, စကားစု, အပိုင်း)
 - Retrieval က query vector(s) နဲ့ document vectors တွေကို ကိုက်ညီအောင် လုပ်ဆောင်တာ ဖြစ်တယ်
 - ကွဲပြားတဲ့ semantic ပုံစံတွေ အတွက် အဆင်ပြေတယ်

- ပိုကြီးတဲ့ မော်ဒယ် != ပိုကောင်းတဲ့ Retrieval
 - geometrically complex but linguistically simple tasks ရှိသြမေတြီအရ ရှုပ်ထွေးပြီး ဘာသာဗေဒအရ ရိုးရှင်းတဲ့ လုပ်ဆောင်စရာတွေ
 - သတ်မှတ်ထားတဲ့ (limited) embedding dimensions တွေနဲ့ Relationship အားလုံးကို satisfy ဖြစ်ဖို့ သင်္ချာနည်းအရ မဖြစ်နိုင်ပါဘူး
 - SOTA (state of the art) မော်ဒယ်တွေဖြစ်တဲ့ Gemini, Llama, Mistral တို့ဟာ recall@100 မှာ 20% အောက်သာ ရရှိခဲ့ပါတယ်
 - BM25 က neural embeddings တွေထက် ပိုကောင်းပြီး အမှတ်တွေဟာ ပြီးပြည့်စုံလှနီးပါး ရရှိခဲ့ပါတယ်
- ဝါကျ 46 ခုတည်းနဲ့တောင် မော်ဒယ်တွေက Top-2 (k=2) ကို မှန်မှန်ကန်ကန် RANK သတ်မှတ်ဖို့ ရုန်းကန်ခဲ့ရတယ်

Weller, O., Boratko, M., Naim, I., & Lee, J. (2025). On the theoretical limitations of embedding-based retrieval. arXiv. <https://arxiv.org/abs/2508.21038>

Thank You

Q and A